

Philosophische Fakultät III Sprach-, Literatur- und Kulturwissenschaften Institut für Information und Medien, Sprache und Kultur (I:IMSK) Lehrstuhl für Informationswissenschaft

Introduction to Natural Language Engineering 2 / Informationslinguistik 2: Sprach- und Texttechnologie

Modul: DH-MA-M07.1

SS 2022

Leitung: Prof. Dr. Kruschwitz

Prävention von Studienabbrüchen:

Ein Question Answering Ratgeber für Studiengänge an der Universität Regensburg

Daniel Alexander Vikete

Matr.-Nr.: 2025386

2. Semester M.A. Digital Humanities

E-Mail: Daniel-Alexander.Vikete@stud.uni-regensburg.de

Kerstin Mayerhofer Matr.-Nr.: 2041508

2. Semester M.A. Digital Humanities

E-Mail: kerstin.mayerhofer@stud.uni-regensburg.de

GitHub-Repository: https://github.com/AlexVike/Infoling-2

Abgegeben am: 06.09.2022

Abstract

Im Rahmen dieses Projekts wird ein Question Answering System für Studiengänge an der Universität Regensburg erstellt, welches zur Prävention von Studienabbrüchen beitragen soll. Mit einem Question Answering System bestehend aus Datenbank, Retriever und Reader können Fragen zu den Studiengängen gestellt werden. Dabei wurde das Open-Source Framework Haystack verwendet. Für den Reader ist ein vortrainiertes Modell zum Einsatz gekommen, welches in diesem Projekt mit eigenen Daten gefinetuned wurde. Durch die Evaluation mit berechneten Scores sowie Proband:innenuntersuchung wird die Funktionsweise des Systems deutlich. F1 und Exact Match scores waren mäßig, jedoch zeigte der Semantic Answer Similarity (SAS) Score, bessere Ergebnisse. So kann darauf geschlossen werden, dass die Antworten des Systems inhaltlich gut sind. Zur besseren Visualisierung wurde eine Webapplikation entwickelt, die das Benutzen des Systems erleichtern soll.

1 Einführung

Die Zahl der Studierenden in Deutschland nimmt stetig zu. Im Jahr 2002 lag die Anzahl der Studierenden bei circa 1.94 Millionen, im Wintersemester 2010/11 stieg die Zahl auf 2.22 Millionen. Im Wintersemester 2020/2021 waren bereits rund 2.94 Millionen Studierende an deutschen Hochschulen immatrikuliert. (Statista, 2022a)

Als interessierte Person an einem Studiengang ist es wichtig, Informationen zu sämtlichen Details der Studiengänge und deren Modulen und Inhalten zu erlangen. Die Auswahl eines richtigen Studiums ist essentiell dafür, dass dieses nicht abgebrochen wird (Heublein & Wolter,

2011). Die Studienmotivation sinkt bei falschen Studienerwartungen, welches einen Abbruch erhöht (Heublein & Wolter, 2011). Studienabbrüche sind ein zentrales Themenfeld der Hochschulforschung sowie der Bildungspolitik, das angesichts aktueller Entwicklungen zusätzlich an Relevanz gewinnt (Neugebauer et al., 2019). Im Jahr 2018 haben 27% der Bachelorstudierenden ihr Studium abgebrochen (Statista, 2022b). Dies scheint sich nicht nur negativ auf die Studienabbrecher:innen auszuwirken, sondern dies bedeutet auch höhere Kosten für den Staat (Berlingieri, Heigle, Pfeiffer & Stichnoth, 2021).

Auch als Student:in in einem fortgeschrittenen Bachelorsemester fallen oft Fragen zu bestimmten Dingen an, die in den Modulkatalogen, den Prüfungsordnungen und den Webseiten zu finden sind. Denn dazu muss der aktuelle Katalog, oder Webseite und die richtige Stelle gefunden werden, was sich oft nicht als sehr einfach herausstellt.

Um nun erfahrene Studenten:innen und vor allem Studieninteressierte zu unterstützen, soll ein Question Answering Ratgeber erstellt werden. Es wird im Sinne eines solchen Projekts versucht, intelligente Systeme zu entwickeln, die nicht nur Dokumente zu einer Frage zurückliefern, sondern auch relevante Informationen aus den Dokumenten extrahieren und eine detaillierte Antwort geben können, wie sie auch ein Mensch gegeben hätte. Dieses wird bei Eingabe des Studiengangs, den entsprechenden Modulkatalog und die entsprechende Prüfungsordnung laden und sämtliche Fragen beantworten können.

2 Analyse

Ziel des Projekts ist eine einfache Methode zu entwickeln, Fragen zu bestimmten Studiengängen schnell zu beantworten. Oft ist das Durchsuchen sämtlicher Webseites und Modulkataloge notwendig, bis eine Frage zu einem bestimmten Studiengang beantwortet werden kann. Da die Webseiten und die Modulkataloge der Universität Regensburg für Studieninteressierte komplett neu sind, kann es zu einer kognitiven Überforderung kommen. Dies kann ein Grund für Fehlentscheidungen sein, sodass eventuell ein falscher Studiengang ausgewählt wird (Croskerry, 2014).

Laut einer Untersuchung von Heublein (2017) wird außerdem ein kritisches Urteil über die Studierfähigkeiten der Studienanfänger:innen gefällt. Dabei herrscht in einigen Universitäten die Meinung vor, dass derzeit die Studierenden zu wenig studierfähig sind. Die meisten Studienanfänger:innen brauchen mindestens ein Semester zur Anpassung an die hochschulischen Anforderungen (Heublein et al., 2017).

Aus diesen Gründen und deren Implikationen, die in dem oberen Abschnitt zu sehen sind, soll ein Question Answering Tool erstellt werden. Diese Aufgabe fällt unter die Bereiche Information Retrieval (IR), Information Extraction (IE) und Natural Language Processing (NLP). Die Idee hinter der Einführung solcher Systeme war es, die anfängliche Unruhe zu beseitigen, mit der diese Systeme im Zusammenhang mit den Anfragen konfrontiert sind (*What is Question Answering? - Hugging Face*, 2022). Heute jedoch ist das Streben nach vollständiger Automatisierung im Gange, und in Chatbots integrierte Systeme zur Beantwortung von Fragen

revolutionieren das digitale Erlebnis (What is Question Answering? - Hugging Face, 2022).

Zur Durchführung werden sämtliche Modulkataloge, Prüfungsordnungen und die Webseiten der Bachelorstudiengänge der Universität Regensburg gesammelt und eingelesen. Nachdem diese eingelesen wurden, kann nach der Verarbeitung der Daten erfolgreich ein Question Answering System entwickelt werden, sodass wichtige Fragen zum Studium direkt automatisch beantwortet werden können. Dazu wird eine Webapplikation entwickelt, die zur Übersichtlichkeit und Benutzerfreundlichkeit dienen soll.

2.1 Verwandte Arbeiten

In diesem Abschnitt werden verwandte Arbeiten dargestellt.

2.2 Question Answering

Systeme zur Beantwortung von Fragen wurden entwickelt, um den menschlichen Informationsbedarf zu decken, der in Situationen wie Gesprächen mit einem virtuellen Assistenten, der Interaktion mit einer Suchmaschine oder der Abfrage einer Datenbank auftreten kann (Jurafsky & Martin, 2021). Die Beantwortung von Fragen war eine der frühesten NLP-Aufgaben. Die textbasierten Algorithmen beruhen im Allgemeinen auf einem einfachen Parsing der Frage und den Sätzen des Dokuments und suchen dann nach Übereinstimmungen. Die meisten Fragebeantwortungssysteme konzentrieren sich auf eine bestimmte Untergruppe dieser Informationsbedürfnisse: faktoide Fragen, d. h. Fragen, die mit einfachen, in kurzen Texten ausgedrückten Fakten beantwortet werden können (Jurafsky & Martin, 2021).

Der generelle Aufbau dieser Systeme bildet sich aus Retriever und Reader. Der Retriever holt sich dabei die Dokumente vom Document Store mit Hilfe der Frage, die gestellt wird. Der Reader bekommt diese Dokumente zur Verfügung gestellt und beantwortet mit ihnen dann die Frage (s. Abbildung 1).

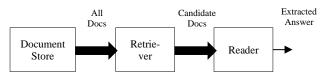


Abbildung 1: Reader Retriever Pipeline angelehnt an Haystacks

Sowohl die Marktführer als auch Newcomer entwickeln seit beträchtlicher Zeit eine ganze Reihe von Algorithmen für den Bereich des Question Answerings (Schneider, 2007). Der allgemeine Verlauf der Entwicklung von Systemen zum Question Answering zeigt, dass hier eine Hinwendung von festen Datenstrukturen zu offenen und kaum strukturierten Datenkollektionen, wie dem Web, stattgefunden hat (Schneider, 2007).

Der größte Anspruch des Question Answerings ist es heutzutage, sowohl die Grenzen des Retrievals (in der Beschränkung auf die Dokumente an sich) und der Informationsextraktion (in der Beschränkung auf eine Domäne) aufzuheben, beziehungsweise neu abzustecken (Jurafsky & Martin, 2021). Die Umsetzung dieses Anspruchs besteht nicht nur in einer Fusion und Weiterentwicklung der bestehenden Algorithmen, sondern auch in einem Rückgriff auf die Erkenntnisse der Künstlichen Intelligenz (Schneider, 2007). Eine zunehmend größere Bedeutung gewinnen zudem die Verfahren aus dem Bereich des Maschinellen Lernens.

Elementar ist von daher die Verfeinerung der einzelnen Module zur Erhöhung der Performanz (Schneider, 2007).

Die Informationswirtschaft bietet allgemein ein großes Betätigungsfeld für diese Technologie. In multimedialen bzw. multimodalen Erweiterungen, wie etwa im Bereich des Spoken Question Answerings oder der Integration in Smart-Phones und mobile digitale Assistenten, um Question Answering zu einem festen Modul in Auskunftssystemen jeder Art werden zu lassen (Schneider, 2007).

2.3 Studienabbruchprävention

Bei der Prävention von Studienabbrüchen gibt es in der aktuellen Forschung verschiedene Ansätze. Oft genannt wird die Studienmotivation, das Self-Assessment, die Beratung, oder die Umstellung des Curriculums (Ebert & Heublein, 2015). An der Universität Göttingen wurde eine virtuelle Studienorientierung geschaffen gegen Studienabbrüche (Alphei & Löffler, 2015). So erhalten Studieninteressierte Informationen zu den Studiengängen und möglichen Berufsbildern (Alphei & Löffler, 2015). Jedoch könnte mit einem QA-System dieser Ansatz noch verbessert werden. In sehr kurzer Zeit können die Studieninteressierten Fragen stellen, ohne dabei einen sehr großen Aufwand betreiben zu müssen, um auf die nötigen Informationen zu stoßen.

3 Methoden

Crawling

Im *DocumentStore* werden die Modulkataloge, die Prüfungsordnungen und die Webseiten hinterlegt. Dazu wurde zuerst ein Script erstellt,

das die Bachelorstudiengänge durchsucht und zur Verfügung stellt. Dafür wurde mit dem Modul Beautiful Soup durch die Webseite "uni-regensburg/studiengänge a-z" gecrawled und, wenn die Bedingung des Titelinhalts "B.A.", "B. Sc.", "Schule" oder "Gymnasium" gegeben war, wurde der Text der Webseite gespeichert. Aus dieser wurden die Daten extrahiert und ein Ordner mit Namen der Webseite erstellt. In diesen Ordner wurde dann die txt-Datei gespeichert. So wurde sichergestellt, dass alle nötigen Studiengänge vorhanden sind. Zusätzlich zu den Informationen der Webseite wurden die Modulkataloge und Prüfungsordnungen der Studiengänge eingelesen und den jeweiligen Ordnern hinzugefügt.

Konvertieren

Um die vorhandenen PDF-Dateien der Modulkataloge und Prüfungsordnungen in eine txt-Datei umzuwandeln, wurde mit dem Modul pdfplumber gearbeitet. Dieses konnte jedoch nicht in allen Fällen die PDF umwandeln, da diese teilweise als Bilder dargestellt wurden. Um dieses Problem zu lösen, wurde Optical Character Recognition (OCR) verwendet. Dieses Tool wandelt jede PDF-Seite als JPEG um und speichert sie als Variable. Dann werden mit OCR auf jeder Seite die Buchstaben erkannt, abgeschrieben und abgespeichert. Der Code wurde so generiert, dass falls eine Umwandlung mit pdfplumber nicht möglich war, der OCR verwendet wurde. Damit war jede PDF nun als txt-Datei vorhanden war. Somit wurden die Daten der Datenbank von Elasticsearch über Docker zur Verfügung gestellt.

Preprocessing

Die zu verwendenden Daten mussten als nächsten Schritt *preprocessed* werden, um mit ihnen arbeiten zu können. Die *PreProcessor*-Klasse von *Haystack* hilft, Texte zu bereinigen und in sinnvolle Einheiten aufzuteilen. Die Aufteilung von Dateien kann sich sehr stark auf die Leistung des Systems auswirken. Dazu werden die txt-Dateien als Docs gespeichert. In den Dokumenten wurden die leeren Zeilen und Leerzeichen entfernt sowie nach 200 Sätzen abgeschnitten, damit kleinere Formate verwendet werden konnten. Dann wurden die Dateien in *Elasticsearch* hochgeladen. Dazu wurde das Tool *Docker* verwendet. Über *Docker* kann die *Elasticsearch* Datenbank gestartet werden.

Question Answering System

Eine Pipeline für das Question Answering System wird mit dem Framework Haystack erstellt. Dabei wird für die Datenbank die Klasse ElasticsearchDocumentStore verwendet. Für den Retriever wird ElasticsearchRetriever verwendet. Für den Reader wird der FarmReader verwendet. Das Framework bietet die Möglichkeit der Verwendung vortrainierter Sprachmodelle. Die Plattform Huggingface stellt derzeit zwei vortrainierte Modelle für die deutsche Sprache zur Verfügung. Das Sprachmodell "deepset/gelectra-base-germanquad-distilled" wurde für diese Arbeit ausgewählt. Bei der normalen - nicht distilled - Version war das Modell zu groß und die Verwendung erwies sich als schwierig, weswegen davon abgesehen wurde. Der Reader und Retriever sind im Anschluss an die Pipeline Klasse Extractive QAP ipeline übergeben worden. Damit das Question Answering System nur einen Studiengang übergeben bekommt, wurde ein Dictionary erstellt. Der Ordner Name der Studiengänge dient dabei als Schlüssel und der Name der Textdateien werden dem Schlüssel als Liste übergeben. Der Vorteil dabei ist, dass der Pipeline der Schlüssel des Dictionary übergeben werden kann und dann nur die Antworten der txt-Dateien in dem jeweiligen Ordner zu Verfügung stehen.

Finetuning

Für das Finetuning wurde das deepset electra base german distilled Modell als Grundlage verwendet. Haystack bietet ein Tool an, mit welchem es möglich ist, Datensätze zu annotieren. Somit wurden Fragen zu unseren Textdateien der Universität erstellt und mit den richtigen Antworten annotiert. Das Modell bräuchte bis zu 2000 Beispiele, um die Leistung um +5-20 % steigern können (Haystack Docs, 2022), was in diesem Fall die Kapazitäten des Projekts überschreiten würde. Um mehr Daten und damit besseres Finetuning zu erlangen, könnte als Lösung beim Benutzen der Webseite in der Zukunft Fragen der User gesammelt werden.

4 Ergebnisse

Als Evaluation wird der Exact Match und der F1-Score verwendet. Exact Match ist eine Metrik, die auf der strikten Zeichenübereinstimmung zwischen der vorhergesagten Antwort und der richtigen Antwort basiert. Die F1-Score-Metrik ist nützlich, wenn wir sowohl falsch-positive als auch falsch-negative Ergebnisse gleich bewerten (What is Question Answering? - Hugging Face, 2022). Der F1-Score wird für jedes Wort in der vorhergesagten Sequenz im Vergleich zur richtigen Antwort

berechnet (What is Question Answering? - Hugging Face, 2022).

Exact Match	F1-Score
10 %	39 %

Tabelle 1: erste Berechnung der Scores

In Tabelle 1 ist zu sehen, dass beide Scores ein mäßiges Ergebnis liefern. Jedoch wurde beim Überprüfen der Antworten festgestellt, dass trotz niedrigen Scores der richtige Inhalt der Antwort gegeben ist. Daraufhin wurde mit semantic answer similarity überprüft, ob die gegebenen Antworten ähnlich sind. Der Score stieg auf 58 %, was ein solides Ergebnis darstellt.

Um den annotierten Datensatz zu bekommen, damit die Evaluation durchgeführt werden konnte, wurden Probanden akquiriert. Auch bei diesem Datensatz wurde das Annotationstool von *Haystack* verwendet. Dazu wurden verschiedene Personen, die kurz vor Beginn eines Studiums stehen, gebeten, sich Fragen zu bestimmten Studiengängen zu überlegen. Dabei wurde darauf geachtet, dass die Probanden auch wirkliches Interesse an den Studiengängen aufweisen. Die Fragen der Versuchspersonen wurden bei der Evaluation verwendet, indem sie in das *Haystack* Tool eingetragen worden sind. Der Datensatz und die Evaluation befinden sich in dem <u>GitHub-Repository</u> zu diesem Projekt.

Die Ergebnisse der Untersuchung lassen auf eine gute Aussagekraft des Question Answering Systems schließen. Für eine bessere Performance gibt es Vorschläge, die unter "Probleme" aufgeführt werden.

Visualisierung

Zur Implementierung des Benutzerinterfaces wurde eine WSGI-App mit Flask implementiert. Diese wird von einem WSGI-Server bereitgestellt. Die Oberfläche wurde mit Hilfe von Bootstrap realisiert. Diese Webseite soll eine leichtere Testung des Systems ermöglichen. Jedoch muss die Webseite als Prototyp angesehen werden, der bei Weiterführung des Projektes noch ausgebaut werden muss. Dabei können die Benuzter:innen der Webanwendung zuerst den Studiengang auswählen, über den sie Informationen suchen und anschließend eine Frage stellen. Die Visualisierung dient zur Erhöhung der Usability und vereinfacht das Verwenden des Question Answering Systems.

Probleme

Einige unerwartete Probleme traten während des Projekts auf, welche hier beschrieben werden.

Das erste Problem war, dass die PDF-Dateien der Universität Regensburg nicht einheitlich gestaltet waren. Dabei zeigte sich, dass manche Dateien als Bilder dargestellt waren und das Extrahieren des Textes so nicht möglich war. Teilweise waren es auch lesbare PDF-Dateien, deren Inhalt jedoch falsch dargestellt wurde. Eine mögliche Lösung, um nicht mit verschiedenen Skripten (wie hier im Projekt) arbeiten zu müssen wäre, dass die Universität einheitliche Regelungen bezüglich des Formats der Modulkataloge und Prüfungsordnungen erstellt.

Als weiteres Problem erwiesen sich die Lehramt-Studiengänge. Diese sind sehr unterschiedlich gestaltet und haben keine gemeinsame Modulordnung sowie ein sehr komplexes System. Deshalb sind die Ergebnisse des Systems bei diesen Studiengängen schlechter als bei allen anderen.

Zusätzlich stellt die Struktur der Prüfungsordnung und der Modulkataloge ein Problem dar. In diesem Projekt wurden die Daten nur bereinigt und vorverarbeitet, jedoch könnte es sich lohnen vor allem die Modulkataloge als Tabellen darzustellen. Mithilfe von regulären Ausdrücken kann dies in Zukunft realisiert werden. Somit könnten *Pandas Dataframes* erstellt werden und der Pipeline übergeben werden. Dies könnte die Performance nochmal erhöhen, hätte aber in diesem Fall, den Rahmen der Arbeit gesprengt.

Zur Verbesserung des Finetunings könnte als Lösung beim Benutzen der Webseite Daten gesammelt werden und jede gestellte Frage analysiert und auf Richtigkeit geprüft werden. Diese Untersuchung könnte abgespeichert und im weiteren Verlauf des Projekts verwendet werden, um eine höhere Anzahl an Beispielen zu erlangen.

5 Zusammenfassung

Das Ziel dieses Projekt war es, ein funktionierendes Question Answering System zu entwickeln und mit diesem, Fragen zu bestimmten Studiengängen beantworten zu können. Das ermöglicht es, dass wichtige Fragen zum Studium direkt automatisch beantwortet werden können. Durch die Evaluation mit berechneten Scores sowie Proband:innenuntersuchung wird die Funktionsweise des Systems deutlich. Zur besseren Visualisierung wurde eine Webapplikation entwickelt, die das Benutzen des Systems erleichtern soll. Dabei können sich Benutzer:innen des Question Answering Systems leichter mit diesem zurechtfinden und dieses öfter verwenden. Somit wurde das Ziel des Projektes erreicht.

6 Zukünftige Arbeiten

Um nun zu überprüfen, ob es einen Einfluss auf die Abbruchquote geben kann, müsste eine Langzeitstudie zu diesem Thema durchgeführt werden.

Als weitere Schritte für das Question Answering System könnten die Lehramt Studiengänge stärker mit eingebunden werden, um umfassendere Informationen zu bekommen. Dies wäre sinnvoll, da an der Universität Regensburg einige Studiengänge in diese Richtung angeboten werden und circa 25% aller Studierenden in einem der Lehramtsstudiengänge eingeschrieben sind (Regensburger Universitätszentrum für Lehrerbildung (RUL). 2022).

Ein weiterer Schritt wäre dann, es in die Webseite der Universität Regensburg mit einzubinden, um als Hochschule einen Nutzen davon zu tragen.

7 Literaturverzeichnis

Alphei , J., & Löffler, U. (2015, October 30).

Herausforderungen und Maßnahmen zur
Prävention des Studienabbruchs an der
Georg-August-Universität Göttingen.

https://www.universitaetsverlagwebler.de/_files/ugd/7bac3c_80152476d1d2434e9c6c5ebefa969fef.pdf#page=34

Berlingieri, F., Heigle, J., Pfeiffer, F. & Stichnoth, H. (2021). Analysen zu Kosten

und Erträgen von Fachwechsel und Studienabbruch. In M. Neugebauer, H.-D. Daniel & A. Wolter (Hrsg.), *Studienerfolg und Studienabbruch* (S. 259–278). Wiesbaden: Springer Fachmedien Wiesbaden. https://doi.org/10.1007/978-3-658-32892-4_11

Croskerry, P. (2014). ED cognition: any decision by anyone at any time. *CJEM*, *16*(1), 13–19.

https://doi.org/10.2310/8000.2013.131053

Ebert, J., & Heublein, U. (2015, October 30).

Studienabbruch an deutschen Hochschulen:
ein Überblick zum Umfang, zu den Ursachen und zu den Voraussetzungen der Prävention. https://www.universitaetsverlagwebler.de/_files/ugd/7bac3c_80152476d1d2434e9c6c5ebefa969fef.pdf#page=7

Haystack Docs. (2022, 7. September). *Haystack Docs*. Zugriff am 07.09.2022. Verfügbar unter: https://haystack.deepset.ai/tutorials/fine-tuning-a-model

Herausforderungen und Maßnahmen zur Prävention des Studienabbruchs an der Georg-August-Universität Göttingen.. Verfügbar unter: https://www.universitaetsverlagwebler.de/_fi-

les/ugd/7bac3c_80152476d1d2434e9c6c5e-befa969fef.pdf#page=34

Heublein, U. & Wolter, A. (2011). Studienabbruch in Deutschland. Definition, Häufigkeit, Ursachen, Maßnahmen. https://doi.org/10.25656/01:8716

Statista. (2022, 25. Junia). Anzahl der Studenten an deutschen Hochschulen bis 2020/2021 / Statista. Zugriff am

25.06.2022. Verfügbar unter: https://de.statista.com/statistik/daten/studie/221/um-frage/anzahl-der-studenten-an-deutschen-hochschulen/

Statista. (2022, 25. Junib). Studienabbruch-quote in den Bachelorstudiengängen an Hochschulen in Deutschland bis 2018 / Statista. Zugriff am 25.06.2022. Verfügbar unter: https://de.statista.com/statistik/daten/studie/883768/umfrage/studienabbruch-quote-in-bachelorstudiengaengen-an-hochschulen-in-deutschland/

What is Question Answering? - Hugging Face. (2022, 25. Juni). Zugriff am 25.06.2022. Verfügbar unter: https://huggingface.co/tasks/question-answering